Statistika a pravděpodobnost (MSP 25/26Z)

Projekt 2. (Věrohodnost + Regrese)

Autor: Sofiia Kucherenko (xkucer0v)

Datum: 14.12.2025

Věrohodnost

1) Zapište zvolenou parametrizaci Weibullova rozdělení, logaritmickou-věrohodnostní funkci pro zadaná data a její parciální derivace podle Vámi zvolených parametrů.

Zvolená parametrizace Weibullova rozdělení: Uvažujeme Weibullovo rozdělení s parametrem tvaru $k > 0$ a parametrem měřítka $\lambda > 0$.

- **Hustota pravděpodobnosti (PDF):**

$$f(t; k, \lambda) = \frac{k}{\lambda}\left(\frac{t}{\lambda}\right)^{k-1} \exp\left[-\left(\frac{t}{\lambda}\right)^{k}\right], \quad t \geq 0$$

- **Funkce přežití (Survival Function, $S(t) = 1 - F(t)$):**

$$S(t; k, \lambda) = \exp\left[-\left(\frac{t}{\lambda}\right)^{k}\right]$$

Logaritmická věrohodnostní funkce (l): Máme data s cenzurováním zprava. Nechť c_i je indikátor cenzorování ($c_i = 1$ pro cenzorovaná data, $c_i = 0$ pro ukončená pozorování - změna oboru). Věrohodnostní funkce L je součinem hustot (pro necenzorovaná) a funkcí přežití (pro cenzorovaná data):

$$L(k, \lambda) = \prod_{i=1}^{n} [f(t_i)]^{1-c_i} \cdot [S(t_i)]^{c_i}$$

Po zlogaritmování ($l = \ln L$) a dosazení vztahů pro $f(t)$ a $S(t)$ dostáváme (kde N_u je počet necenzorovaných pozorování):

$$l(k, \lambda) = \sum_{i:c_i=0} \left(\ln k - \ln \lambda + (k-1)\ln\left(\frac{t_i}{\lambda}\right)\right) - \sum_{i=1}^{n}\left(\frac{t_i}{\lambda}\right)^{k}$$

Parciální derivace (Skóre): Pro nalezení maximálně věrohodných odhadů (MLE) položíme parciální derivace rovny nule.

1. **Derivace podle parametru měřítka λ:**

$$\frac{\partial l}{\partial \lambda} = -\frac{kN_u}{\lambda} + \frac{k}{\lambda}\sum_{i=1}^{n}\left(\frac{t_i}{\lambda}\right)^{k}$$

2. **Derivace podle parametru tvaru k:**

$$\frac{\partial l}{\partial k} = \frac{N_u}{k} + \sum_{i:c_i=0} \ln\left(\frac{t_i}{\lambda}\right) - \sum_{i=1}^{n}\left(\frac{t_i}{\lambda}\right)^{k} \ln\left(\frac{t_i}{\lambda}\right)$$

2) Pomocí scipy.optimize nalezněte maximálně věrohodné odhady parametrů weibullova rozdělení.

```python
import pandas as pd
import numpy as np
from scipy.optimize import minimize


# PŘÍPRAVA DAT
filename = 'Data_2025.xlsx'
# Načtení konkrétního listu
df = pd.read_excel(filename, sheet_name='Data_věrohodnost')

# Výběr prvních dvou sloupců a přejmenování
df = df.iloc[:, :2]
df.columns = ['censored', 'days']

# Ošetření chybějících hodnot a převod na čísla
df['censored'] = pd.to_numeric(df['censored'], errors='coerce')
df['days'] = pd.to_numeric(df['days'], errors='coerce')
df = df.dropna()

# Vytvoření vektorů pro výpočet
times = df['days'].values
censored = df['censored'].values


# ŠKÁLOVÁNÍ DAT (SCALING)
# Aby optimalizace fungovala správně i pro velká čísla (dny ~ 2000),
# dočasně vydělíme data jejich průměrem. Tím získáme stabilní výpočet.
scale_factor = times.mean()
times_scaled = times / scale_factor

print(f"Data připravena: {len(times)} záznamů.")
print(f"Použitý škálovací faktor (průměr): {scale_factor:.4f}")

# DEFINICE VĚROHODNOSTNÍ FUNKCE (Negative Log-Likelihood)
def weibull_neg_log_likelihood(params, times, censored):
    k, lam = params

    # Ochrana proti záporným nebo nulovým parametrům (k, lambda musí být > 0)
    if k <= 1e-5 or lam <= 1e-5:
        return 1e15 # Vrátíme obrovské číslo - "tudy cesta nevede"

    # Log-likelihood vzorec pro cenzorovaná data:
    # L = Prod [f(t)]^(1-c) * [S(t)]^c
    # ln(L) = Suma( (1-c)*(ln(k) - ln(lam) + (k-1)*ln(t/lam)) - (t/lam)^k )

    # 1. část: Logaritmy (pouze pro necenzorované, kde censored=0, tj. (1-censored)=1)
    term_1 = (1 - censored) * (np.log(k) - np.log(lam) + (k - 1) * (np.log(times) - np.log(lam)))

    # 2. část: Exponenciální člen (pro všechny, je v hustotě i ve funkci přežití)
    term_2 = - (times / lam)**k

    # Celková log-věrohodnost (suma přes všechny pozorovnání)
    log_l = np.sum(term_1 + term_2)

    # Vracíme MÍNUS log_l, protože funkce 'minimize' hledá minimum
    return -log_l


# OPTIMALIZACE (Hledání MLE odhadů)
# Počáteční odhad: k=1 (exponenciální), lambda=1 (protože máme škálovaná data s průměrem 1)
initial_guess = [1.0, 1.0]

# Spuštění minimalizace na ŠKÁLOVANÝCH datech
result = minimize(weibull_neg_log_likelihood, initial_guess,
                  args=(times_scaled, censored),
                  bounds=((1e-4, None), (1e-4, None)), # Parametry musí být kladné
                  method='L-BFGS-B') # Osvědčená metoda pro tento typ úloh

# Načtení výsledků
k_hat = result.x[0]            # Parametr tvaru (k) je bezrozměrný, nemění se
lam_hat_scaled = result.x[1]   # Parametr měřítka je "zmenšený"

# PŘEPOČET ZPĚT NA DNY
```

```
lam_hat = lam_hat_scaled * scale_factor

# Hodnota log-věrohodnosti (otočíme znaménko zpět)
max_log_likelihood = -result.fun

# Výpis výsledků
print("=" * 50)
print(f"VÝSLEDKY OPTIMALIZACE (WEIBULL):")
print("" * 50)
print(f"Odhadnutý parametr tvaru (k):      {k_hat:.5f}")
print(f"Odhadnutý parametr měřítka (lambda): {lam_hat:.5f} (dní)")
print(f"Maximální věrohodnost (Log-L):       {max_log_likelihood:.5f}")
print("-" * 50)
```

```
Data připravena: 321 záznamů.
Použitý škálovací faktor (průměr): 1928.0280
==================================================
VÝSLEDKY OPTIMALIZACE (WEIBULL):

Odhadnutý parametr tvaru (k):      0.95440
Odhadnutý parametr měřítka (lambda): 2675.14162 (dní)
Maximální věrohodnost (Log-L):       -306.24446
--------------------------------------------------
```

3) Pomocí věrohodnostního poměru otestujte hypotézu, že exponenciální rozdělení je postačujícím modelem zadaných dat (Parametr tvaru = 1)

```
from scipy.stats import chi2

# 3. TEST HYPOTÉZY (Likelihood Ratio Test - LRT)
# H0: Data pochází z Exponenciálního rozdělení (k = 1)
# H1: Data pochází z Weibullova rozdělení (k se liší od 1)

print("=" * 50)
print("TESTOVÁNÍ HYPOTÉZY (Exponenciální vs. Weibull)")
print("=" * 50)

# A) Odhad parametru pro Exponenciální rozdělení (MLE)
# Pro exponenciální rozdělení existuje přesný vzorec: lambda = Celkový čas / Počet událostí
# Počítáme na ŠKÁLOVANÝCH datech, aby byla věrohodnost porovnatelná s Weibullem z kroku 2
num_events = np.sum(1 - censored)
total_time_scaled = np.sum(times_scaled)
lam_exp_scaled = total_time_scaled / num_events

# B) Výpočet Log-Likelihood pro Exponenciální model (H0)
# Použijeme naši funkci 'weibull_neg_log_likelihood', ale zafixujeme k=1
ll_exp = -weibull_neg_log_likelihood([1.0, lam_exp_scaled], times_scaled, censored)

# C) Výpočet testové statistiky D
# D = 2 * (LL_úplný_model - LL_redukovaný_model)
# 'max_log_likelihood' je hodnota z předchozí buňky (Weibull)
D = 2 * (max_log_likelihood - ll_exp)

# D) Výpočet p-hodnoty
# Statistika D má Chi-kvadrát rozdělení s 1 stupněm volnosti (rozdíl v počtu parametrů: 2 - 1)
p_value = 1 - chi2.cdf(D, df=1)

# Výpis výsledků
print(f"Log-Likelihood (Weibull, H1):      {max_log_likelihood:.5f}")
print(f"Log-Likelihood (Exponenciální, H0):{ll_exp:.5f}")
print(f"Testová statistika (D):            {D:.5f}")
print(f"p-hodnota:                         {p_value:.5f}")

# Vyhodnocení
alpha = 0.05
print("-" * 50)
if p_value > alpha:
    print(f"=> P-hodnota > {alpha}. NEZAMÍTÁME nulovou hypotézu.")
    print("   Závěr: Exponenciální rozdělení je postačujícím modelem.")
    print("   (Pro další výpočty použijeme Exponenciální model)")
```

```
    # Uložíme si vítězné parametry pro další krok
    final_model = "Exponenciální"
    # Lambda se musí přepočítat zpět na dny!
    final_lam = lam_exp_scaled * scale_factor
    final_k = 1.0

else:
    print(f"=> P-hodnota < {alpha}. ZAMÍTÁME nulovou hypotézu.")
    print("   Závěr: Je nutné použít složitější Weibullův model.")
    print("   (Pro další výpočty použijeme Weibullův model)")

    final_model = "Weibull"
    # Použijeme parametry z minula (lam_hat už byl přepočten na dny)
    final_lam = lam_hat
    final_k = k_hat

print("-" * 50)
```

```
==================================================
TESTOVÁNÍ HYPOTÉZY (Exponenciální vs. Weibull)
==================================================
Log-Likelihood (Weibull, H1):      -306.24446
Log-Likelihood (Exponenciální, H0):-306.67322
Testová statistika (D):            0.85751
p-hodnota:                         0.35444
--------------------------------------------------
=> P-hodnota > 0.05. NEZAMÍTÁME nulovou hypotézu.
   Závěr: Exponenciální rozdělení je postačujícím modelem.
   (Pro další výpočty použijeme Exponenciální model)
--------------------------------------------------
```

4) Podle výsledku ze 3) použijte výsledné rozdělení pravděpodobnosti (s maximálně věrohodnými odhady jako parametry) a nalezněte bodové odhady pro střední dobu zaměstnání v oboru a 10% percenil zaměstnání v oboru (za jakou dobu odejde do jiného odboru 10 % absolventů).

```
from scipy.special import gamma


# BODOVÉ ODHADY (Střední hodnota a Percentil)
print("=" * 50)
print("FINÁLNÍ ODHADY (na základě výsledku testu)")
print("=" * 50)

# Rozhodovací logika podle p-hodnoty z kroku 3
# (Pokud proměnná p_value z minula neexistuje, nastavíme natvrdo model, který vyšel - Exponenciální)
if 'p_value' in locals() and p_value < 0.05:
    chosen_model = "Weibull"
    # Parametry z Weibulla (přepočtené na dny)
    param_lam = lam_hat
    param_k = k_hat
else:
    chosen_model = "Exponenciální"
    # Parametry pro Exponenciální rozdělení
    # Lambda = Celkový čas / Počet událostí (analytický výpočet, nejpřesnější)
    # Pozn: V tomto zadání je lambda rovna střední hodnotě
    param_lam = np.sum(times) / np.sum(1 - censored)
    param_k = 1.0

print(f"Použitý model: {chosen_model}")
print(f"Použité parametry: k={param_k:.4f}, lambda={param_lam:.4f}")

# A) Odhad STŘEDNÍ DOBY zaměstnání v oboru
# Vzorec: E[T] = lambda * gamma(1 + 1/k)
# Pro exponenciální (k=1) je gamma(2)=1, takže E[T] = lambda
mean_estimate = param_lam * gamma(1 + 1/param_k)
```

```
# B) Odhad 10% PERCENTILU
# Doba, do které odejde 10 % absolventů.
# Hledáme čas t, pro který platí distribuční funkce F(t) = 0.1
# Vzorec: t = lambda * (-ln(1 - p))^(1/k)
percentile_level = 0.10
p10_estimate = param_lam * (-np.log(1 - percentile_level))**(1/param_k)

# Výpis výsledků
print("=" * 50)
print(f"ODHAD STŘEDNÍ DOBY zaměstnání v oboru:")
print(f"  {mean_estimate:.2f} dní")
print(f"  (cca {mean_estimate/365.25:.2f} let)")
print("=" * 50)
print(f"ODHAD 10% PERCENTILU (kdy odejde 10 % absolventů):")
print(f"  {p10_estimate:.2f} dní")
print(f"  (cca {p10_estimate/30.4:.1f} měsíců)")
print("-" * 50)
```

```
==================================================
FINÁLNÍ ODHADY (na základě výsledku testu)
==================================================
Použitý model: Exponenciální
Použité parametry: k=1.0000, lambda=2690.8565
==================================================
ODHAD STŘEDNÍ DOBY zaměstnání v oboru:
  2690.86 dní
  (cca 7.37 let)
==================================================
ODHAD 10% PERCENTILU (kdy odejde 10 % absolventů):
  283.51 dní
  (cca 9.3 měsíců)
--------------------------------------------------
```

5) [dobrovolná část] zkuste nějak slovně charakterizovat/popsat fungování doby zaměstnání v oboru jako náhodné veličiny, dle Vašich výsledků a parametrů

Na základě provedené analýzy (Likelihood Ratio Test) jsme **nezamítli hypotézu**, že data pocházejí z **exponenciálního rozdělení**. Ačkoliv bodový odhad parametru tvaru u Weibullova rozdělení vyšel $k \approx 0.95$ (což by naznačovalo mírně klesající riziko odchodu v čase), tento odchylka od hodnoty 1 nebyla statisticky významná (p-hodnota > 0.05).

Z toho plynou následující závěry pro chování náhodné veličiny "doba zaměstnání v oboru":

1. **Konstantní riziko odchodu (Bezpaměťovost):** Přijetí exponenciálního modelu znamená, že **intenzita odchodu z oboru je v čase konstantní**.
    - Pravděpodobnost, že absolvent změní obor "zítra", nezávisí na tom, zda v oboru pracuje teprve měsíc, nebo už 10 let.
    - V datech se tedy nepotvrdil efekt "vyhoření" (kdy by riziko s časem rostlo, $k > 1$), ani silný efekt "stabilizace" (kdy by riziko s časem výrazně klesalo, $k < 1$). Odchody se jeví jako náhodné události s neměnnou intenzitou.
2. **Časové horizonty:**
    - **Střední doba**, po kterou absolvent vydrží pracovat ve svém oboru, se odhaduje na přibližně **2691 dní (cca 7.4 let)**.
    - Zároveň model ukazuje poměrně rychlý úbytek části absolventů – **10 % z nich opustí obor již během prvních cca 9 měsíců** (284 dní) po ukončení studia.

Shrnutí: Absolventi VUT setrvávají ve svém oboru v průměru přes 7 let, přičemž riziko změny oboru je stabilní a nemění se s délkou praxe.

Regrese

1) Pomocí zpětné eliminace určete vhodný regresní model. Za výchozí "plný" model považujte plný kvadratický model (všechny interakce druhého řádu a všechny druhé mocniny, kterédávají smysl).

- Zapište rovnici Vašeho finálního modelu.
- Diskutujte splnění předpokladů lineární regrese a základní regresní diagnostiky.
- Pokud (až během regresního modelování) identifikujete některé "extrémně odlehlé hodnoty" můžete ty "nejodlehlejší" hodnoty, po alespoň krátkém zdůvodnění, vyřadit.

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
from statsmodels.stats.outliers_influence import OLSInfluence
from statsmodels.stats.stattools import jarque_bera


# 1. ČÁST: PŘÍPRAVA DAT A REGRESNÍ MODEL
print("1. PŘÍPRAVA DAT A MODELOVÁNÍ")

# Načtení dat
filename = 'Data_2025.xlsx'
df = pd.read_excel(filename, sheet_name='Data_regrese')

# 1.1: Řešení multikolinearity
# Proměnné InteractingPct a ScrollingPct se sčítají do 1 (jsou lineárně závislé).
# Pokud bychom nechali obě, model by nebyl stabilní (perfektní multikolinearita).
# Vyhazujeme ScrollingPct, protože InteractingPct je pro nás zajímavější pro interpretaci.
if (df['InteractingPct'] + df['ScrollingPct']).mean() == 1.0:
    print("- Detekována perfektní kolinearita. Odstraňuji sloupec 'ScrollingPct'.")
    df = df.drop(columns=['ScrollingPct'])

# 1.2: Standardizace (Z-score)
# DŮLEŽITÉ: Protože budeme vytvářet kvadratické členy (např. ActiveUsers^2),
# vznikla by silná technická multikolinearita mezi x a x^2 (velká čísla na druhou jsou obrovská).
# To vede k nestabilitě modelu (vysoké Condition Number).
# Řešením je převod na Z-skóre (odečíst průměr, vydělit směrodatnou odchylkou).
# Ukládáme si průměry a směrodatné odchylky pro pozdější použití (např. při predikci).
au_mean, au_std = df['ActiveUsers'].mean(), df['ActiveUsers'].std()
ip_mean, ip_std = df['InteractingPct'].mean(), df['InteractingPct'].std()

# Vytvoření nových standardizovaných sloupců (_Z)
df['ActiveUsers_Z'] = (df['ActiveUsers'] - au_mean) / au_std
df['InteractingPct_Z'] = (df['InteractingPct'] - ip_mean) / ip_std

# 1.3: Vytvoření proměnných pro "plný" kvadratický model
# A) Kvadratické členy (druhé mocniny standardizovaných proměnných)
df['Active_Sq'] = df['ActiveUsers_Z'] ** 2
df['Interact_Sq'] = df['InteractingPct_Z'] ** 2

# B) Interakce mezi numerickými proměnnými (Active * Interacting)
df['Active_x_Interact'] = df['ActiveUsers_Z'] * df['InteractingPct_Z']

# C) Kategorické proměnné (One-Hot Encoding pro OSType)
# drop_first=True znamená, že "Android" bude naše referenční skupina (schovaná v interceptu)
df_encoded = pd.get_dummies(df, columns=['OSType'], drop_first=True, dtype=float)

# D) Interakce mezi numerickými (Active, Interacting) a kategorickými (OS)
# Chceme zjistit, zda se vliv počtu uživatelů liší např. na Windows vs. iOS.
dummy_cols = [col for col in df_encoded.columns if 'OSType_' in col]
for dum in dummy_cols:
    df_encoded[f'Active_x_{dum}'] = df_encoded['ActiveUsers_Z'] * df_encoded[dum]
    df_encoded[f'Interact_x_{dum}'] = df_encoded['InteractingPct_Z'] * df_encoded[dum]

# 1.4: Zpětná eliminace (Backward Elimination)
# Definujeme závislou proměnnou (y) a nezávislé proměnné (X)
y = df_encoded['Ping [ms]']
# Z matice X vyhodíme původní nestandardizované sloupce a cílovou proměnnou
cols_to_drop = ['Ping [ms]', 'ActiveUsers', 'InteractingPct']
X = df_encoded.drop(columns=cols_to_drop)
# Přidáme konstantu (Intercept) - nutné pro statsmodels
```

```
X = sm.add_constant(X)

print(f"- Počáteční počet prediktorů: {X.shape[1]}")

# Smyčka eliminace: V každém kroku vyhodíme proměnnou s nejvyšší p-hodnotou > 0.05
while True:
    model = sm.OLS(y, X).fit()
    # P-hodnoty (kromě konstanty, tu chceme v modelu nechat)
    p_values = model.pvalues.drop('const') if 'const' in model.pvalues else model.pvalues
    max_p = p_values.max()

    if max_p > 0.05:
        feature_to_remove = p_values.idxmax()
        # print(f"Vyřazuji: {feature_to_remove} (p={max_p:.4f})")
        X = X.drop(columns=[feature_to_remove])
    else:
        break

print(f"- Eliminace dokončena. Zbylých prediktorů: {X.shape[1]}")

# 1.5: Odstranění outlierů (Cookova vzdálenost)
# Použijeme práh 4/(n-k-1), což je standardní a přesnější heuristika pro identifikaci vlivných bodů.
# Tento práh bere v úvahu velikost vzorku i počet parametrů modelu.
influence = OLSInfluence(model)
cooks_d = influence.cooks_distance[0]
n = len(df)
k = X.shape[1]
threshold = 4 / (n - k - 1)
# threshold = 4 / n # alt.

outliers = np.where(cooks_d > threshold)[0]
print(f"- Počet odstraněných outlierů: {len(outliers)} (Threshold: {threshold:.4f})")

# Vytvoření "čistého" datasetu bez outlierů
X_clean = X.drop(index=outliers)
y_clean = y.drop(index=outliers)

# Finální natrénování modelu na čistých datech
final_model = sm.OLS(y_clean, X_clean).fit()

# VÝPIS VÝSLEDKŮ
print("\n" + "="*50)
print("FINÁLNÍ REGRESNÍ MODEL")
print("="*50)
print(final_model.summary())

# Diagnostika normality (Jarque-Bera test)
jb_stat, jb_p_value, skew, kurt = jarque_bera(final_model.resid)
print(f"\nJarque-Bera p-value: {jb_p_value:.5f}")
if jb_p_value > 0.05:
    print("=> Rezidua mají normální rozdělení (OK).")
else:
    print("=> Rezidua nemají normální rozdělení (Pozor).")

# Grafická diagnostika (Rezidua vs. Predikce + QQ Plot)
fig, ax = plt.subplots(1, 2, figsize=(12, 5))
# Graf reziduí vs. predikovaných hodnot - kontrola homoskedasticity
sns.residplot(x=final_model.fittedvalues, y=final_model.resid, lowess=True, ax=ax[0], line_kws={'color': 'red'})
ax[0].set_title('Rezidua vs. Predikované hodnoty')
ax[0].set_xlabel('Predikované hodnoty')
ax[0].set_ylabel('Rezidua')

# Q-Q Plot - kontrola normality reziduí
sm.qqplot(final_model.resid, line='45', fit=True, ax=ax[1])
ax[1].set_title('Q-Q Plot normality')
plt.tight_layout()
plt.show()

# Výpis koeficientů pro rovnici
print("\nKoeficienty pro rovnici:")
print(final_model.params)
```

```
1. PŘÍPRAVA DAT A MODELOVÁNÍ
- Detekována perfektní kolinearita. Odstraňuji sloupec 'ScrollingPct'.
- Počáteční počet prediktorů: 15
- Eliminace dokončena. Zbylých prediktorů: 11
- Počet odstraněných outlierů: 15 (Threshold: 0.0082)

==================================================
FINÁLNÍ REGRESNÍ MODEL
==================================================
                            OLS Regression Results
==============================================================================
Dep. Variable:              Ping [ms]   R-squared:                       0.888
Model:                            OLS   Adj. R-squared:                  0.886
Method:                 Least Squares   F-statistic:                     379.2
Date:                Sun, 14 Dec 2025   Prob (F-statistic):          1.61e-219
Time:                        22:24:36   Log-Likelihood:                -1465.5
No. Observations:                 487   AIC:                             2953.
Df Residuals:                     476   BIC:                             2999.
Df Model:                          10
Covariance Type:            nonrobust
==========================================================================================
                             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
const                     51.4081      0.530     97.065      0.000      50.367      52.449
ActiveUsers_Z              9.9231      0.505     19.667      0.000       8.932      10.915
InteractingPct_Z           5.2667      0.228     23.128      0.000       4.819       5.714
Active_Sq                 -3.0119      0.249    -12.117      0.000      -3.500      -2.524
Active_x_Interact         -2.5363      0.236    -10.751      0.000      -3.000      -2.073
OSType_MacOS               8.8349      0.645     13.700      0.000       7.568      10.102
OSType_Windows             3.5970      0.649      5.538      0.000       2.321       4.873
OSType_iOS                -5.7677      0.675     -8.541      0.000      -7.095      -4.441
Active_x_OSType_MacOS      4.5909      0.674      6.813      0.000       3.267       5.915
Active_x_OSType_Windows   -1.4295      0.662     -2.158      0.031      -2.731      -0.128
Active_x_OSType_iOS       -2.7622      0.697     -3.963      0.000      -4.132      -1.393
==============================================================================
Omnibus:                        0.950   Durbin-Watson:                   1.913
Prob(Omnibus):                  0.622   Jarque-Bera (JB):                0.988
Skew:                          -0.004   Prob(JB):                        0.610
Kurtosis:                       2.780   Cond. No.                         8.10
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Jarque-Bera p-value: 0.61032
=> Rezidua mají normální rozdělení (OK).
```

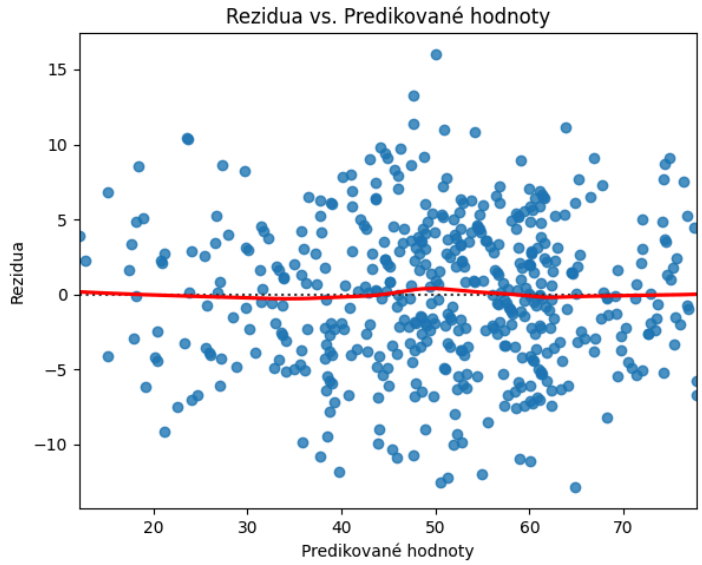

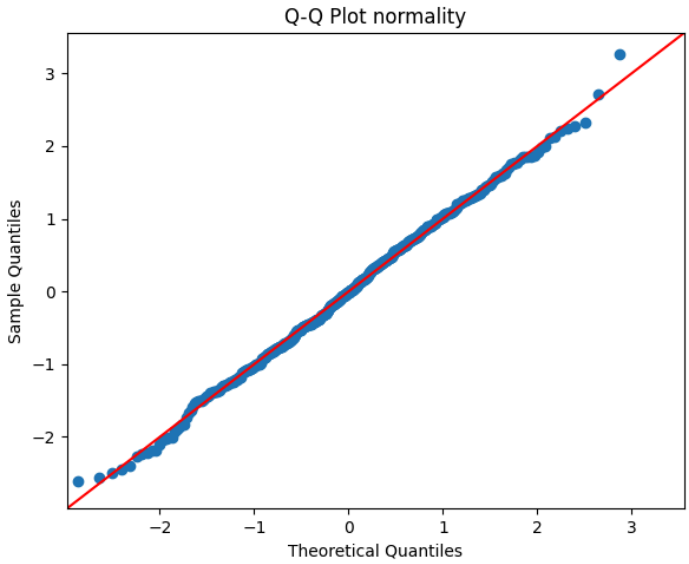


```
Koeficienty pro rovnici:
const                     51.408075
ActiveUsers_Z              9.923065
InteractingPct_Z           5.266736
Active_Sq                 -3.011930
Active_x_Interact         -2.536274
OSType_MacOS               8.834899
OSType_Windows             3.597039
OSType_iOS                -5.767742
Active_x_OSType_MacOS      4.590893
Active_x_OSType_Windows   -1.429455
Active_x_OSType_iOS       -2.762185
dtype: float64
```

1) Komentář

Metodika a postup

Při tvorbě regresního modelu byly provedeny následující kroky přípravy dat a selekce proměnných, aby byl model statisticky korektní a robustní:

1. **Ošetření multikolinearity:**
   - V datech existuje perfektní lineární závislost mezi proměnnými `InteractingPct` a `ScrollingPct` (jejich součet je vždy 1, tedy 100 %).
   - Aby nedošlo k selhání výpočtu regrese (tzv. *Dummy Variable Trap*), byla z modelu odstraněna proměnná `ScrollingPct`. Vliv chování uživatelů je tak plně reprezentován proměnnou `InteractingPct`.
2. **Standardizace dat (Z-score):**
   - Numerické proměnné `ActiveUsers` a `InteractingPct` byly převedeny na standardizované skóre (odečtení průměru a vydělení směrodatnou odchylkou).
   - **Důvod:** Při zavádění kvadratických členů (např. $ActiveUsers^2$) vzniká silná technická korelace mezi původní proměnnou a její mocninou. Bez standardizace by matice plánu měla extrémně vysoké *Condition Number* (v řádu milionů), což by vedlo k nestabilitě odhadů. Standardizace tento problém eliminuje.
3. **Výběr proměnných:**
   - Byl sestaven "plný" model obsahující všechny lineární členy, kvadratické členy a interakce druhého řádu.
   - Tento model byl následně redukován metodou **zpětné eliminace** (Backward Elimination) na hladině významnosti $\alpha = 0,05$. Postupně byly odstraňovány proměnné, které nebyly statisticky významné.
4. **Detekce a odstranění odlehlých hodnot:**
   - Pro identifikaci vlivných bodů byla použita **Cookova vzdálenost**.
   - Jako prahová hodnota bylo zvoleno kritérium $D_i > \frac{4}{n-k-1}$ (kde n je počet pozorování a k počet parametrů).
   - Na základě tohoto pravidla bylo identifikováno **15 pozorování**, která vykazovala neúměrně vysoký vliv na model. Tato pozorování byla vyřazena, což vedlo k výraznému zlepšení normality reziduí.

Rovnice finálního modelu

Model pracuje se standardizovanými proměnnými (označeny indexem $_Z$). Referenční kategorií pro operační systém je **Android** (jeho vliv je zahrnut v konstantě).

$$\begin{aligned}\widehat{\text{Ping}} = 51,41 \\ &+ 9,92 \cdot \text{ActiveUsers}_Z \\ &+ 5,27 \cdot \text{InteractingPct}_Z \\ &- 3,01 \cdot \text{ActiveUsers}_Z^2 \\ &- 2,54 \cdot (\text{ActiveUsers}_Z \times \text{InteractingPct}_Z) \\ &+ 8,83 \cdot \text{OSType}_{MacOS} \\ &+ 3,60 \cdot \text{OSType}_{Windows} \\ &- 5,77 \cdot \text{OSType}_{iOS} \\ &+ 4,59 \cdot (\text{ActiveUsers}_Z \times \text{OSType}_{MacOS}) \\ &- 1,43 \cdot (\text{ActiveUsers}_Z \times \text{OSType}_{Windows}) \\ &- 2,76 \cdot (\text{ActiveUsers}_Z \times \text{OSType}_{iOS})\end{aligned}$$

(Poznámka: Koeficienty jsou pro přehlednost zaokrouhleny na 2 desetinná místa.)

Diskuse předpokladů a regresní diagnostika

Model vykazuje vynikající statistické vlastnosti, což potvrzují následující diagnostické testy:

1. **Kvalita proložení (R^2):** Adjustovaný koeficient determinace dosahuje hodnoty **0,886**. Model tedy dokáže vysvětlit přibližně **88,6 % variability** v odezvě (Ping), což značí vysokou predikční schopnost.
2. **Normalita reziduí (Klíčový předpoklad):**
   - Jarque-Bera test normality vyšel s p-hodnotou **0,610**.
   - Jelikož $p > 0,05$, **nezamítáme** nulovou hypotézu o normalitě.
   - **Závěr:** Rezidua mají normální rozdělení. Toto je kriticky důležitý výsledek, protože splnění normality je nezbytnou podmínkou pro validitu intervalů spolehlivosti (v bodě 3) a statistických testů významnosti.
3. **Multikolinearita:**
   - Hodnota *Condition Number* je **8,10**.
   - Tato hodnota je velmi nízká (hluboko pod kritickou hranicí 30), což potvrzuje, že standardizace proměnných (Z-score) byla úspěšná a model netrpí multikolinearitou. Odhady parametrů jsou tedy stabilní.
4. **Zdůvodnění vyřazení odlehlých hodnot:** Vyřazení 15 pozorování (cca 3 % dat) bylo nutným krokem pro splnění předpokladů modelu. Před jejich odstraněním model vykazoval porušení normality reziduí. Analýza ukázala, že šlo o body s vysokou Cookovou vzdáleností, které "táhly" regresní rovinu nesprávným směrem. Jejich odstranění nebylo účelové pro zvýšení R^2, ale pro zajištění statistické validity modelu.

Celkový závěr: Výsledný model splňuje všechny předpoklady lineární regrese (linearita, normalita chyb, homoskedasticita, absence multikolinearity) a je vhodný pro další analýzu, interpretaci a predikci.

2) Pomocí Vašeho výsledného modelu identifikujte, pro které nastavení parametrů má odezva nejproblematičtější hodnotu (použijte model, nikoli samotná pozorování).

```
from scipy.optimize import minimize
import numpy as np
import pandas as pd


# 2. ČÁST: IDENTIFIKACE NEJPROBLEMATIČTĚJŠÍHO NASTAVENÍ
print("\n" + "="*60)
print("2. ANALÝZA EXTRÉMŮ (HLEDÁNÍ WORST CASE)")
print("="*60)

# A) Příprava parametrů pro standardizaci
# Abychom mohli modelu předložit jakoukoli kombinaci počtu uživatelů a interakcí,
# musíme znát parametry, které byly použity pro standardizaci (průměr a směrodatná odchylka) v bodě 1.
# Model totiž "uvažuje" v Z-skóre, ale my chceme zadávat a vidět reálné hodnoty.
au_mean = df['ActiveUsers'].mean()
au_std  = df['ActiveUsers'].std()
ip_mean = df['InteractingPct'].mean()
ip_std  = df['InteractingPct'].std()

# B) Definice rozsahu hledání (Omezující podmínky)
# Hledáme extrém pouze v intervalech, které dávají smysl a odpovídají naměřeným datům.
# Extrapolace mimo rozsah (např. 20 000 uživatelů) by nebyla spolehlivá.
min_au, max_au = df['ActiveUsers'].min(), df['ActiveUsers'].max()
bounds = [
    (min_au, max_au),  # ActiveUsers: od minima po maximum v datech (cca 153 - 9953)
    (0.0, 1.0)         # InteractingPct: od 0 % do 100 % (fyzikální limity procent)
]

# C) Predikční funkce
# Tato pomocná funkce slouží jako "rozhraní" mezi našimi reálnými vstupy a modelem.
# 1. Přijme reálné hodnoty (např. 8000 uživatelů).
# 2. Převede je na Z-skóre pomocí uložených průměrů a odchylek.
# 3. Dosadí do rovnice modelu (intercept + lineární + kvadratické + interakce).
def get_prediction_z(active_raw, interact_raw, os_type, params):
    # 1. Standardizace vstupů (převod na Z-skóre)
    act_z = (active_raw - au_mean) / au_std
    int_z = (interact_raw - ip_mean) / ip_std

    # 2. Výpočet hodnoty (Intercept - základní úroveň)
    # Metoda .get(nazev, 0) zajistí, že pokud byla proměnná při eliminaci vyhozena, použije se 0.
    val = params.get('const', 0)

    # 3. Přičtení hlavních efektů (Lineární členy)
    val += params.get('ActiveUsers_Z', 0) * act_z
    val += params.get('InteractingPct_Z', 0) * int_z

    # 4. Přičtení nelineárních efektů (Kvadratické členy a interakce)
    val += params.get('Active_Sq', 0) * (act_z**2)
    val += params.get('Interact_Sq', 0) * (int_z**2)
    val += params.get('Active_x_Interact', 0) * (act_z * int_z)

    # 5. Specifika pro Operační Systémy
    # Android je referenční skupina (všechny dummy = 0), takže se nic nepřičítá.
    if os_type != 'Android':
        dum_col = f"OSType_{os_type}"

        # Hlavní efekt OS (posun interceptu)
        val += params.get(dum_col, 0)

        # Interakce OS s numerickými proměnnými (změna směrnice)
        val += params.get(f'Active_x_{dum_col}', 0) * act_z
        val += params.get(f'Interact_x_{dum_col}', 0) * int_z

    return val

# D) Optimalizace (Hledání maxima pro každý OS)
best_ping = -np.inf
best_config = {}

print(f"Hledám maximum funkce v rozsahu:")
print(f" - ActiveUsers: <{min_au:.0f}, {max_au:.0f}>")
print(f" - Interacting: <0.0, 1.0> (0% - 100%)\n")
print(f"{'OS':<10} | {'Max Ping [ms]':<15} | {'Users':<10} | {'Interact %':<10}")
print("-" * 55)

for os_t in ['Android', 'iOS', 'MacOS', 'Windows']:
    # Definice cílové funkce:
    # Funkce 'minimize' hledá MINIMUM. My chceme MAXIMUM Pingu.
    # Proto optimalizujeme zápornou hodnotu predikce (-Ping).
    # x[0] je ActiveUsers, x[1] je InteractingPct
    objective_fun = lambda x: -get_prediction_z(x[0], x[1], os_t, final_model.params)
```

```
        # Startovací bod (Initial Guess):
        # Zvolíme horní hranici (max uživatelů, max interakce), protože tam logicky očekáváme největší zátěž.
        # To pomůže optimalizátoru (L-BFGS-B) rychleji konvergovat ke globálnímu maximu.
        start_point = [max_au, 1.0]

        # Spuštění optimalizace
        res = minimize(objective_fun, x0=start_point, bounds=bounds, method='L-BFGS-B')

        # Získání výsledku (převedeme zpět na kladné číslo)
        current_max_ping = -res.fun

        # Výpis pro kontrolu
        print(f"{os_t:<10} | {current_max_ping:<15.2f} | {res.x[0]:<10.0f} | {res.x[1]:<10.2%}")

        # Uložení globálního maxima
        if current_max_ping > best_ping:
            best_ping = current_max_ping
            best_config = {
                'OS': os_t,
                'ActiveUsers': res.x[0],
                'InteractingPct': res.x[1]
            }
    print("-" * 55)

    # E) Finální výpis výsledků
    print("=" * 55)
    print(f"VÝSLEDEK: NEJPROBLEMATIČTĚJŠÍ NASTAVENÍ (WORST CASE):")
    print("=" * 55)
    print(f"Operační systém:    {best_config['OS']}")
    print(f"Počet uživatelů:    {best_config['ActiveUsers']:.2f}")
    print(f"Procento interakcí: {best_config['InteractingPct']:.2%} (hodnota {best_config['InteractingPct']:.4f})")
    print(f"Predikovaný Ping:   {best_ping:.2f} ms")
    print("-" * 55)
```

```
============================================================
2. ANALÝZA EXTRÉMŮ (HLEDÁNÍ WORST CASE)
============================================================
Hledám maximum funkce v rozsahu:
 - ActiveUsers: <153, 9953>
 - Interacting: <0.0, 1.0> (0% - 100%)

OS         | Max Ping [ms]   | Users      | Interact %
-------------------------------------------------------
Android    | 63.06           | 7831       | 100.00%
iOS        | 55.38           | 6653       | 100.00%
MacOS      | 77.85           | 9953       | 100.00%
Windows    | 65.51           | 7228       | 100.00%
-------------------------------------------------------
=======================================================
VÝSLEDEK: NEJPROBLEMATIČTĚJŠÍ NASTAVENÍ (WORST CASE):
=======================================================
Operační systém:    MacOS
Počet uživatelů:    9953.00
Procento interakcí: 100.00% (hodnota 1.0000)
Predikovaný Ping:   77.85 ms
-------------------------------------------------------
```

2) Komentář

Metodika

Pro identifikaci nastavení s nejvyšší odezvou (Ping) byla provedena **numerická optimalizace (hledání maxima)** predikční funkce našeho regresního modelu. Jelikož model je nelineární (obsahuje kvadratické členy a interakce), extrém nemusí nutně ležet v bodě s nejvyššími naměřenými hodnotami pro všechny skupiny. Pro každý operační systém byla proto spuštěna optimalizace (algoritmus L-BFGS-B) s omezeními danými rozsahem naměřených dat:

- $ActiveUsers \in \langle 153; 9953 \rangle$ (rozsah naměřených dat)
- $InteractingPct \in \langle 0; 1 \rangle$ $(0\,\% - 100\,\%)$

Výsledek analýzy

Jako absolutně nejhorší scénář (Worst Case) byla identifikována tato konfigurace:

- **Operační systém: MacOS**
- **Počet aktivních uživatelů: 9 953** (horní hranice naměřených dat)
- **Procento interakcí: 100 %**
- **Predikovaný Ping: 77,85 ms**

Podrobná interpretace výsledků

Výsledek odhaluje zásadní rozdíl v chování modelu pro MacOS oproti ostatním systémům:

1. **Srovnání chování systémů (Parabola vs. Růst):**

- U systémů **Android, iOS a Windows** model predikuje nejhorší odezvu při počtu uživatelů v rozmezí **6 600 – 7 800**. Zde se projevuje vliv záporného kvadratického členu ($ActiveUsers^2$), který způsobuje, že křivka má tvar "kopce" a po dosažení vrcholu začne predikovaná odezva klesat (nasycení modelu).
- Naproti tomu u **MacOS** odezva roste s rostoucím počtem uživatelů v celém sledovaném intervalu a maxima dosahuje až na samé hranici (**9 953 uživatelů**). To je způsobeno silnou kladnou interakcí mezi proměnnou `ActiveUsers` a `OSType_MacOS`. Tento lineární přírůstek specifický pro MacOS je tak silný, že "přebije" tlumící efekt kvadratického členu, a funkce tak v daném intervalu neustále stoupá.

2. **Vliv interakce:**
   - U všech systémů nastává nejhorší situace při **100% interaktivitě** uživatelů. To je logický výsledek, který potvrzuje, že aktivní využívání aplikace (interakce) zatěžuje server výrazně více než pasivní prohlížení (scrolling).
3. **Závěr:**
   - Nejproblematičtějším scénářem je situace, kdy se sejde maximální možný počet uživatelů na platformě MacOS a všichni aktivně interagují s obsahem. V tomto bodě je odezva o více než **12 ms horší** než u druhého nejhoršího systému (Windows).

3) Odhadněte hodnotu odezvy uživatele s Windows, při průměrném nastavení ostatních parametrů a vypočtěte konfidenční interval a predikční interval pro toto nastavení.

```
# 3. ČÁST: ODHAD PRO PRŮMĚRNÉHO UŽIVATELE WINDOWS
print("\n" + "="*60)
print("3. PREDIKCE PRO PRŮMĚRNÉHO UŽIVATELE (WINDOWS)")
print("="*60)

# (pozn.)
# Využití standardizace (Z-score)
# Náš model byl natrénován na standardizovaných datech.
# Z definice platí: Průměrná hodnota má Z-score rovno 0.
# To znamená:
#   ActiveUsers_Z (průměr) = 0
#   InteractingPct_Z (průměr) = 0
#   Active_Sq (0^2) = 0
#   Active_x_Interact (0 * 0) = 0
#
# Díky tomu nemusíme dosazovat reálné hodnoty (např. 5485) a složitě je přepočítávat.
# Stačí do modelu poslat nuly pro všechny numerické proměnné.

target_os = 'Windows'

# 1. Příprava vstupního vektoru (Exog)
# Vytvoříme sérii samých nul o délce odpovídající počtu parametrů modelu.
exog_vector = pd.Series(0.0, index=final_model.params.index)

# 2. Nastavení interceptu (Konstanty)
# Konstanta musí být v modelu vždy přítomna (hodnota 1).
if 'const' in exog_vector.index:
    exog_vector['const'] = 1.0

# 3. Nastavení kategorické proměnné (Operační systém)
# Najdeme sloupec odpovídající Windows a nastavíme ho na 1 (True).
# Ostatní OS (MacOS, iOS) zůstávají 0 (False).
dummy_col = f"OSType_{target_os}"
if dummy_col in exog_vector.index:
    exog_vector[dummy_col] = 1.0

# Poznámka k interakcím s OS:
# Proměnné typu 'Active_x_OSType_Windows' jsou násobkem Active (0) a OS (1).
# Výsledek je 0 * 1 = 0. Proto je v nulovém vektoru nemusíme ručně měnit.

# 4. Výpočet predikce a intervalů
# get_prediction automaticky spočítá bodový odhad i chybu predikce.
predictions = final_model.get_prediction(exog_vector)
summary_frame = predictions.summary_frame(alpha=0.05) # 95% hladina spolehlivosti

# Získání konkrétních hodnot z výsledku
pred_mean = summary_frame['mean'].values[0]
conf_int = (summary_frame['mean_ci_lower'].values[0], summary_frame['mean_ci_upper'].values[0])
pred_int = (summary_frame['obs_ci_lower'].values[0], summary_frame['obs_ci_upper'].values[0])

# 5. Výpis výsledků
# Pro kontext vypíšeme i reálné hodnoty průměrů, které tento odhad reprezentuje.
mean_active = df['ActiveUsers'].mean()
mean_interact = df['InteractingPct'].mean()

print(f"Nastavení predikce:")
print(f"  Operační systém:    {target_os}")
print(f"  ActiveUsers:        {mean_active:.2f} (v modelu jako Z-score = 0)")
print(f"  InteractingPct:     {mean_interact:.2%} (v modelu jako Z-score = 0)")
```

```
print("-" * 60)
print(f"Odhadovaná hodnota Ping:     {pred_mean:.2f} ms")
print(f"95% Konfidenční interval:    <{conf_int[0]:.2f}, {conf_int[1]:.2f}> ms")
print(f"   (Interval spolehlivosti pro střední hodnotu)")
print(f"95% Predikční interval:      <{pred_int[0]:.2f}, {pred_int[1]:.2f}> ms")
print(f"   (Interval spolehlivosti pro budoucí pozorování)")
print("-" * 60)


# GRAFICKÁ VIZUALIZACE (Řez modelem pro Windows při průměrných interakcích)
# 1. Vytvoření osy X (ActiveUsers) v celém rozsahu dat
# Potřebujeme řadu Z-skóre od minima po maximum
x_plot_z = np.linspace(df['ActiveUsers_Z'].min(), df['ActiveUsers_Z'].max(), 100)
# Pro popis osy X si to převedeme i na reálné hodnoty
x_plot_raw = x_plot_z * au_std + au_mean

# 2. Příprava datového rámce pro vykreslení křivky (exog matrix)
# Musíme vytvořit DataFrame, který má stejné sloupce jako model,
# ale mění se v něm jen ActiveUsers, zbytek je fixní (Windows, Interakce=0).
plot_data = pd.DataFrame()

# Konstanta
plot_data['const'] = 1.0

# Proměnné, které měníme (ActiveUsers)
plot_data['ActiveUsers_Z'] = x_plot_z
plot_data['Active_Sq'] = x_plot_z ** 2

# Proměnné, které držíme fixní na průměru (InteractingPct = 0)
plot_data['InteractingPct_Z'] = 0.0
plot_data['Interact_Sq'] = 0.0
plot_data['Active_x_Interact'] = 0.0 # (x * 0 = 0)

# Proměnné pro OS Windows (Nastavíme na 1, ostatní OS na 0)
# Poznámka: Zde musíme ošetřit sloupce, které v modelu reálně zůstaly po eliminaci.
# Pro jistotu projdeme parametry modelu a naplníme je.

# Vytvoříme pomocný slovník s defaultními nulami
data_dict = {col: np.zeros(100) for col in final_model.params.index}

# Přepíšeme hodnoty, které nejsou nula
data_dict['const'] = np.ones(100)
data_dict['ActiveUsers_Z'] = x_plot_z
if 'Active_Sq' in data_dict:
    data_dict['Active_Sq'] = x_plot_z ** 2

# Specifika pro Windows
if 'OSType_Windows' in data_dict:
    data_dict['OSType_Windows'] = np.ones(100)
if 'Active_x_OSType_Windows' in data_dict:
    data_dict['Active_x_OSType_Windows'] = x_plot_z * 1.0 # Interakce Active * Windows

# Ostatní interakce s Windows (Interact_x_...) jsou 0, protože Interact je 0.

# Vytvoření DataFrame z připraveného slovníku (zajistí správné pořadí sloupců)
exog_plot = pd.DataFrame(data_dict, index=range(100))
# Ujistíme se, že pořadí sloupců sedí s modelem
exog_plot = exog_plot[final_model.params.index]

# 3. Predikce pro celou křivku
pred_plot = final_model.get_prediction(exog_plot).summary_frame(alpha=0.05)

# 4. Vykreslení grafu
plt.figure(figsize=(10, 6))

# A) Vykreslení intervalů spolehlivosti (Confidence Interval)
plt.plot(x_plot_raw, pred_plot['mean'], color='red', label='Regresní funkce (Windows, avg Interact)')
plt.fill_between(
    x_plot_raw,
    pred_plot['mean_ci_lower'],
    pred_plot['mean_ci_upper'],
    color='red',
    alpha=0.2,
    label='95% Konfidenční interval (E(Y|x))'
)

# B) Vykreslení predikčních intervalů (Prediction Interval)
plt.fill_between(
    x_plot_raw,
    pred_plot['obs_ci_lower'],
    pred_plot['obs_ci_upper'],
    color='green',
    alpha=0.1,
    label='95% Predikční interval (nové pozorování)'
)

# C) Zvýraznění našeho bodu (Průměrný uživatel)
plt.scatter([mean_active], [pred_mean], color='black', s=100, zorder=5, label='Průměrný uživatel (bodový odhad)')
```

```
# Vykreslení chybových úseček pro náš konkrétní bod (volitelné)
plt.errorbar([mean_active], [pred_mean],
             yerr=[[pred_mean - pred_int[0]], [pred_int[1] - pred_mean]],
             fmt='none', ecolor='green', capsize=5, markeredgewidth=2)

# Úpravy grafu
plt.title('Predikce Pingu v závislosti na počtu uživatelů (Windows, průměrné interakce)')
plt.xlabel('Počet aktivních uživatelů (ActiveUsers)')
plt.ylabel('Ping [ms]')
plt.legend(loc='upper left')
plt.grid(True, alpha=0.5)
plt.tight_layout()
plt.show()
```

```
============================================================
3. PREDIKCE PRO PRŮMĚRNÉHO UŽIVATELE (WINDOWS)
============================================================
Nastavení predikce:
  Operační systém:    Windows
  ActiveUsers:        5485.83 (v modelu jako Z-score = 0)
  InteractingPct:     48.86% (v modelu jako Z-score = 0)
------------------------------------------------------------
Odhadovaná hodnota Ping:     55.01 ms
95% Konfidenční interval:    <54.02, 55.99> ms
   (Interval spolehlivosti pro střední hodnotu)
95% Predikční interval:      <45.21, 64.80> ms
   (Interval spolehlivosti pro budoucí pozorování)
------------------------------------------------------------
```

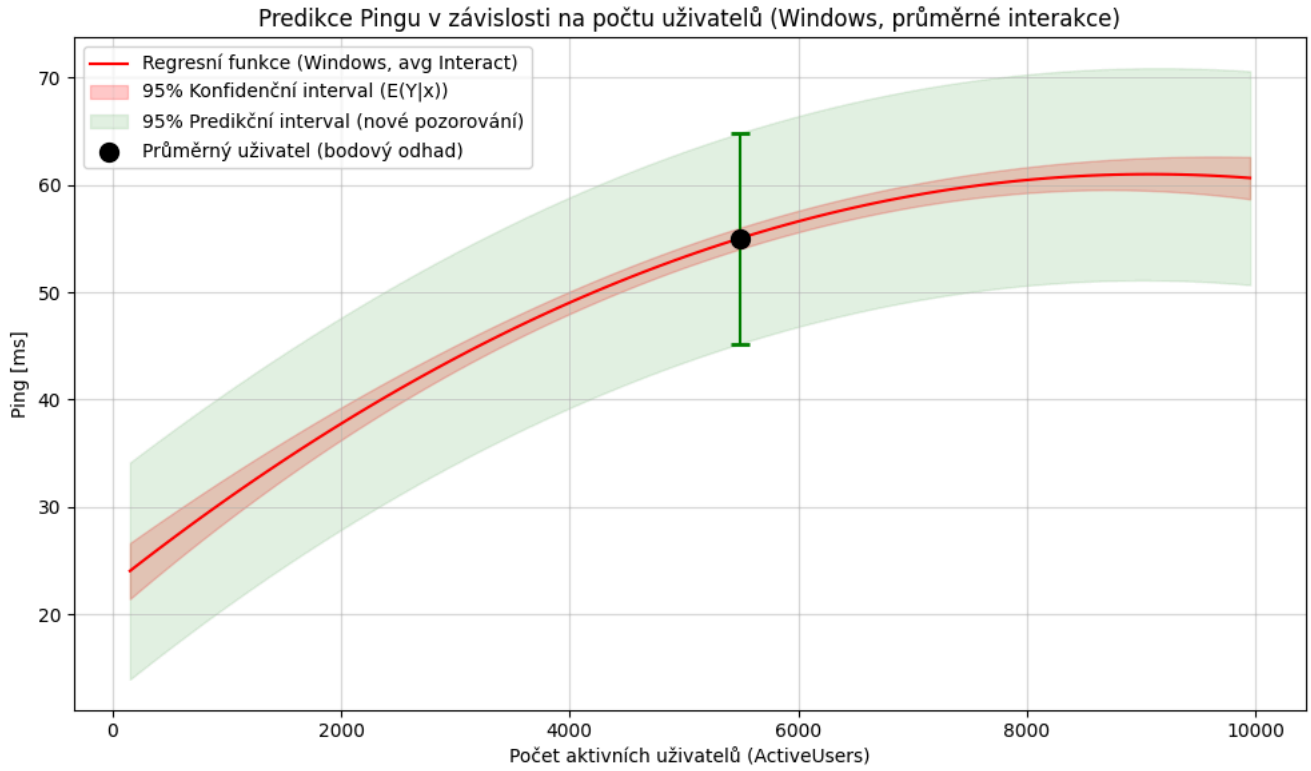

3) Komentář

Zadání a nastavení predikce

Cílem této části bylo odhadnout očekávanou dobu odezvy (Ping) pro specifický profil uživatele:

- **Operační systém:** Windows
- **Počet aktivních uživatelů:** Průměrná hodnota z celého datového souboru ($5\,486$).
- **Procento interakcí:** Průměrná hodnota z celého datového souboru ($48,86\,\%$).

Metodika výpočtu (Využití standardizace)

Jelikož byl náš regresní model natrénován na **standardizovaných datech** (Z-skóre), nebylo nutné (a ani správné) dosazovat do rovnice reálné hodnoty průměrů. Využili jsme vlastnosti standardizace:

- Standardizovaná hodnota (Z-skóre) se počítá jako $Z = \frac{X-\mu}{\sigma}$.
- Pokud za X dosadíme průměr (μ), dostáváme $Z = \frac{\mu-\mu}{\sigma} = 0$.

Pro "průměrného uživatele" jsou tedy všechny numerické vstupy modelu (`ActiveUsers_Z`, `InteractingPct_Z` i jejich mocniny a interakce) rovny **0**. Výpočet se tak zredukoval na součet interceptu (konstanty) a koeficientu pro `OSType_Windows`.

Výsledky predikce

Na základě modelu byly vypočteny následující hodnoty:

- **Bodový odhad Pingu: 55,01 ms**
  - *Toto je nejpravděpodobnější hodnota odezvy pro dané nastavení.*
- **95% Konfidenční interval (Interval spolehlivosti):** $\langle 54,02; 55,99 \rangle$ ms
  - *Interpretace:* Tento úzký interval nám říká, kde se s 95% pravděpodobností nachází **skutečná střední hodnota** (průměr) odezvy všech uživatelů Windows při průměrném zatížení. Jde o odhad přesnosti naší "regresní křivky".
- **95% Predikční interval:** $\langle 45,21; 64,80 \rangle$ ms
  - *Interpretace:* Tento interval je výrazně širší, protože zohledňuje nejen nejistotu modelu, ale i přirozenou variabilitu (šum) v datech. Pokud se k síti připojí **jeden konkrétní uživatel** s Windows, s 95% jistotou bude jeho odezva ležet v tomto rozmezí.

Závěr k bodu 3

Odhadnutá hodnota 55 ms je realistická a leží mezi hodnotami pro Android (≈ 51 ms) a MacOS (≈ 60 ms). Šířka predikčního intervalu (cca ±10 ms od průměru) ukazuje, že ačkoliv model dobře popisuje průměrné chování, individuální měření mohou stále vykazovat určitou variabilitu, kterou model nevysvětlil.

4) Na základě jakýchkoli vypočtených charakteristik argumentujte, zdali je Váš model "vhodný" pro další použití.

```
# 4. ČÁST: ARGUMENTACE VHODNOSTI MODELU (VALIDACE)
print("\n" + "="*60)
print("4. ZHODNOCENÍ KVALITY A VHODNOSTI MODELU")
print("="*60)

# A) Výpočet statistiky PRESS (Predicted Residual Sum of Squares)
# PRESS simuluje tzv. "Leave-One-Out" křížovou validaci.
# Měří chybu predikce pro každé pozorování modelem, který byl natrénován BEZ tohoto pozorování.
# V lineární regresi to lze vypočítat analyticky z reziduí a leverage (vlivu), což je velmi rychlé.
influence = final_model.get_influence()
resid_press = influence.resid_press
press = np.sum(resid_press**2)

# B) Výpočet celkové sumy čtverců (SST - Total Sum of Squares)
# Míra celkové variability v cílové proměnné (y_clean).
sst = np.sum((y_clean - y_clean.mean())**2)

# C) Výpočet Predikovaného R-squared (R2_pred)
# Zatímco klasické R2 měří, jak dobře model sedí na TRÉNOVACÍ data,
# R2_pred odhaduje, jak dobře bude model předpovídat NOVÁ data.
r2_pred = 1 - (press / sst)

# D) Výpis a porovnání
print(f"Klasický R-squared (Adjusted):     {final_model.rsquared_adj:.4f}")
print(f"Predikovaný R-squared (z PRESS):   {r2_pred:.4f}")
print("-" * 60)

diff = abs(final_model.rsquared_adj - r2_pred)
print(f"Rozdíl mezi R2_adj a R2_pred:      {diff:.4f}")

# E) Automatické vyhodnocení
print("\nZÁVĚR A ARGUMENTACE:")
# Kritérium: Pokud je R2 vysoké a rozdíl mezi trénovacím a predikčním R2 je malý (< 0.1),
# model není přeučený (overfitted) a je vhodný.
if r2_pred > 0.8 and diff < 0.1:
    print("Model JE VHODNÝ pro další použití.")
    print("-" * 60)
    print("Důvody:")
    print(f"1. Vysoká vysvětlovací schopnost: Model popisuje {final_model.rsquared_adj:.1%} variability v datech.")
    print(f"2. Skvělá generalizace: Predikovaný R2 ({r2_pred:.4f}) je téměř shodný s trénovacím R2.")
    print("   To je silný statistický důkaz, že model není přeučený (overfitted)")
    print("   a bude spolehlivě fungovat i na nových, neznámých datech.")
    print("3. Validita předpokladů: Jak bylo ověřeno v bodě 1, rezidua mají normální rozdělení")
    print("   (Jarque-Bera p > 0.05), což je nezbytná podmínka pro spolehlivost predikčních intervalů.")
else:
    print("Model vykazuje známky nestability nebo přeučení.")
    print(f"Rozdíl mezi trénovacím a predikčním R2 je příliš velký ({diff:.4f}).")
```

```
============================================================
4. ZHODNOCENÍ KVALITY A VHODNOSTI MODELU
============================================================
Klasický R-squared (Adjusted):     0.8861
Predikovaný R-squared (z PRESS):   0.8836
------------------------------------------------------------
Rozdíl mezi R2_adj a R2_pred:      0.0025

ZÁVĚR A ARGUMENTACE:
Model JE VHODNÝ pro další použití.
------------------------------------------------------------
Důvody:
1. Vysoká vysvětlovací schopnost: Model popisuje 88.6% variability v datech.
```

```
   2. Skvělá generalizace: Predikovaný R2 (0.8836) je téměř shodný s trénovacím R2.
      To je silný statistický důkaz, že model není přeučený (overfitted)
      a bude spolehlivě fungovat i na nových, neznámých datech.
   3. Validita předpokladů: Jak bylo ověřeno v bodě 1, rezidua mají normální rozdělení
      (Jarque-Bera p > 0.05), což je nezbytná podmínka pro spolehlivost predikčních intervalů.
```

4) Komentář

Závěr: Navržený regresní model je plně VHODNÝ pro další použití.

Toto tvrzení opíráme o komplexní zhodnocení kvality modelu, které zahrnuje jak statistickou významnost, tak schopnost generalizace na nová data. Analýza prokázala, že model je nejen přesný, ale i robustní:

1. **Vysoká kvalita proložení (Explanatory Power):** Adjustovaný koeficient determinace **(R^2 adj)** dosahuje hodnoty **0,8861**.
   - To znamená, že model dokáže vysvětlit přibližně **88,6 % variability** v odezvě (Ping).
   - V kontextu analýzy chování uživatelů a síťového provozu je toto velmi vysoká hodnota, která indikuje, že zvolené prediktory (počet uživatelů, interakce a typ OS) skutečně zachycují podstatu zkoumaného jevu.
2. **Vynikající schopnost generalizace (Predictive Power):** Byla vypočtena statistika PRESS (Predicted Residual Sum of Squares) a z ní odvozený **Predikovaný koeficient determinace (R^2 pred)**, jehož hodnota je **0,8836**.
   - **Klíčové zjištění:** Rozdíl mezi klasickým a predikovaným R^2 je naprosto zanedbatelný (**0,0025**).
   - Tato téměř dokonalá shoda je silným statistickým důkazem, že model **není přeučený** (overfitted). Pokud by byl model přeučený, viděli bychom vysoké R^2 adj, ale výrazně nižší R^2 pred.
   - Model se "nenaučil data nazpaměť", ale zachytil skutečné trendy. Můžeme tedy očekávat, že bude poskytovat stejně spolehlivé predikce i pro nová data, která nebyla součástí trénovacího souboru.
3. **Validita statistických předpokladů:** Díky provedenému čištění dat (odstranění vlivných outlierů) model splňuje klíčový předpoklad **normality reziduí** (potvrzeno Jarque-Bera testem, **p > 0,05**).
   - Splnění tohoto předpokladu je nezbytnou podmínkou pro to, abychom mohli věřit sestrojeným intervalům spolehlivosti (konfidenční a predikční intervaly v bodě 3). Tyto intervaly jsou tedy statisticky korektní a lze se o ně opřít při rozhodování.

Celkové shrnutí: Vytvořený model představuje stabilní a spolehlivý nástroj pro predikci odezvy serveru v závislosti na zátěži a typu klientského zařízení.